



Previsão de Carga Elétrica

PROJETO APLICADO IV

Bianca Rezk de Angelo Correa - RA 10435117

Bruna Fagundes Pereira Queiroz - RA 10433417

Caio Cesar Teixeira Rocha - RA 10435091

Livya Kaizer de Albuquerque - RA 10433409

Lucas Feo Mazzei - RA 10433452

São Paulo

2026

RESUMO

Este trabalho tem como objetivo analisar e prever o consumo diário de energia elétrica a partir da base Electricity Load Diagrams 2011-2014, utilizando técnicas de séries temporais e modelos estatísticos de previsão. A relevância do estudo está relacionada ao crescimento da demanda energética e à necessidade de planejamento eficiente do setor elétrico, contribuindo para a redução de custos operacionais e para o uso sustentável dos recursos energéticos. Como recorte metodológico, foi selecionado o consumidor MT_124 da base de dados, e as medições registradas a cada 15 minutos foram agregadas em frequência diária para reduzir ruídos e complexidade analítica. O trabalho envolve etapas de exploração e pré-processamento dos dados, engenharia de atributos temporais e aplicação de modelos preditivos, incluindo Persistência, Média Móvel e SARIMA. A avaliação dos modelos foi realizada por meio das métricas MAE, RMSE e MAPE, permitindo comparar desempenho e capacidade preditiva. Os resultados indicam forte dependência temporal de curto prazo na série analisada e apontam possibilidades de evolução com modelos de aprendizado de máquina.

Palavras-chave: previsão de carga elétrica; séries temporais; SARIMA; consumo de energia; planejamento energético.

SUMÁRIO

1 INTRODUÇÃO	4
2 REFERENCIAL TEÓRICO	5
3 METODOLOGIA	6
4 RESULTADOS E DISCUSSÃO	8
5 CONCLUSÃO E PROJETOS FUTUROS	9
6 REFERÊNCIAS	10

1 INTRODUÇÃO

A previsão de carga elétrica constitui um dos principais desafios do setor energético moderno, sendo essencial para o planejamento da geração, distribuição e consumo de energia elétrica. No Brasil, o consumo final de eletricidade alcançou 650,4 TWh em 2024, representando crescimento de 5,5% em relação ao ano anterior (EPE, 2025). Esse cenário reforça a importância de soluções analíticas capazes de apoiar decisões mais eficientes e sustentáveis no gerenciamento energético.

Nesse contexto, técnicas de Ciência de Dados aplicadas a séries temporais permitem modelar padrões históricos de consumo e gerar previsões de demanda. Estimativas imprecisas podem provocar aumento de custos operacionais, desperdício de recursos e dificuldades no equilíbrio entre oferta e demanda. Assim, previsões mais adequadas podem auxiliar concessionárias, operadores de rede e consumidores na otimização do sistema elétrico.

A base utilizada neste projeto foi a Electricity Load Diagrams 2011-2014, disponibilizada pela UCI Machine Learning Repository. Ela contém medições de consumo elétrico de 370 clientes, registradas a cada 15 minutos, compondo um cenário adequado para análise de tendência, sazonalidade e dependência temporal.

Como recorte metodológico, foi selecionado o consumidor MT_124 e adotada a frequência diária para a série analisada. Essa escolha permitiu reduzir a complexidade computacional e concentrar a análise em uma série temporal específica, tornando o projeto mais viável dentro do escopo acadêmico.

O objetivo geral do projeto é analisar o comportamento temporal do consumo de energia elétrica e desenvolver modelos preditivos capazes de estimar a demanda diária do consumidor selecionado. Como objetivos específicos, busca-se caracterizar a base de dados, selecionar um consumidor para análise, transformar os registros de 15 minutos em frequência diária, identificar padrões temporais e aplicar modelos de previsão para comparação de desempenho.

2 REFERENCIAL TEÓRICO

Séries temporais são conjuntos de observações coletadas em ordem cronológica. Em problemas de previsão, o objetivo é utilizar padrões históricos para estimar valores futuros, considerando componentes como tendência, sazonalidade e variabilidade (HYNDMAN; ATHANASOPOULOS, 2021). No contexto energético, a previsão de carga é relevante por apoiar decisões operacionais e estratégicas.

Entre os modelos estatísticos tradicionais de séries temporais destacam-se ARIMA e SARIMA. O modelo ARIMA combina componentes autorregressivos, diferenciação e médias móveis. Já o SARIMA incorpora componentes sazonais, permitindo modelar padrões recorrentes ao longo do tempo, como ciclos semanais ou anuais (BOX et al., 2015).

A estacionariedade é um conceito importante para modelos autorregressivos. Uma série estacionária apresenta propriedades estatísticas relativamente estáveis ao longo do tempo. Quando a série não é estacionária, pode ser necessário aplicar diferenciação para reduzir tendências e tornar a modelagem mais adequada.

A autocorrelação também é fundamental nesse tipo de análise, pois mede a relação entre observações da série em diferentes defasagens. Gráficos de autocorrelação e autocorrelação parcial ajudam a identificar dependências temporais e a orientar a escolha de modelos e parâmetros.

Além dos modelos estatísticos, técnicas de aprendizado de máquina também são aplicadas à previsão energética. Modelos como Random Forest e Gradient Boosting podem capturar relações não lineares e interações entre variáveis, enquanto redes LSTM são capazes de aprender dependências de longo prazo em sequências temporais (HOCHREITER; SCHMIDHUBER, 1997; HONG; FAN, 2016). Neste projeto, foram adotados inicialmente modelos baseline e SARIMA, mantendo simplicidade e interpretabilidade.

3 METODOLOGIA

A metodologia foi organizada em etapas sequenciais de aquisição, preparação, análise, modelagem e avaliação dos dados. O fluxo adotado buscou transformar os dados brutos em uma série temporal diária adequada para previsão.

3.1 Base de dados e recorte adotado

A base Electricity Load Diagrams 2011-2014 contém medições de consumo elétrico de 370 clientes, com registros em intervalos de 15 minutos. O arquivo original possui uma coluna temporal e 370 colunas de consumo, no formato MT_001 a MT_370. Para este trabalho, foi selecionado o consumidor MT_124 como recorte principal.

A escolha de apenas um consumidor reduziu a complexidade da análise e permitiu aprofundar a exploração de uma única série temporal. Embora esse recorte limite a generalização dos resultados, ele torna a abordagem mais viável e interpretável.

3.2 Pré-processamento dos dados

Inicialmente, os dados foram carregados em formato texto, com separador ponto e vírgula e vírgula como separador decimal. A coluna temporal foi convertida para o formato datetime e utilizada como índice da série. Em seguida, a série do cliente MT_124 foi selecionada para análise.

Como a base original apresentava medições a cada 15 minutos, os valores foram convertidos para kWh e agregados em frequência diária. Considerando que cada hora possui quatro medições de 15 minutos, os registros foram ajustados e somados por dia, resultando em uma série de consumo diário.

Na etapa de qualidade dos dados, foram verificados valores nulos, registros zerados e possíveis valores extremos. Os consumos iguais a zero foram substituídos por valores ausentes e tratados por interpolação temporal, preservando a continuidade da série.

3.3 Análise exploratória e engenharia de atributos

A análise exploratória contemplou visualização da série diária, estatísticas descritivas, decomposição temporal, análise por dia da semana e mês, além de gráficos de autocorrelação e autocorrelação parcial. Essas etapas permitiram identificar dependência temporal, sazonalidade semanal e variações ao longo dos meses.

A partir desses achados, foram criadas variáveis temporais e variáveis derivadas da própria série: dia da semana, mês, dia do ano, lags de 1, 7 e 30 dias e médias móveis de 7 e 30

dias. Essas variáveis auxiliam na captura de padrões recentes, semanais e tendências suavizadas de consumo.

3.4 Modelagem e validação

A divisão dos dados respeitou a ordem cronológica da série. Os anos de 2011 a 2013 foram utilizados para treinamento, enquanto o ano de 2014 foi reservado para teste. Essa estratégia evita vazamento de informação e simula uma situação real de previsão futura.

Foram aplicados três modelos: Persistência, Média Móvel de 7 dias e SARIMA. O modelo de Persistência utiliza o consumo do dia anterior como previsão. A Média Móvel utiliza a média dos sete dias anteriores. O SARIMA foi configurado como SARIMA(1,1,1)(1,1,1,7), incorporando sazonalidade semanal.

A avaliação foi realizada por meio das métricas MAE, RMSE e MAPE. O MAE mede o erro absoluto médio, o RMSE penaliza erros maiores e o MAPE expressa o erro em termos percentuais, permitindo comparar diferentes aspectos do desempenho preditivo.

4 RESULTADOS E DISCUSSÃO

A análise exploratória indicou que o consumo do cliente MT_124 apresenta dependência temporal e padrões sazonais. Foram observadas diferenças entre dias úteis e finais de semana, além de variações mensais. Esses padrões justificaram o uso de variáveis defasadas, médias móveis e modelos temporais.

A Tabela 1 apresenta a comparação de desempenho dos modelos avaliados com base nas métricas MAE, RMSE e MAPE.

Tabela 1 - Comparação de desempenho dos modelos

Modelo	MAE	RMSE	MAPE (%)
Persistência (lag-1)	645,41	947,96	57,07
Média Móvel (7 dias)	716,28	922,10	58,64
SARIMA(1,1,1)(1,1,1,7)	797,64	1072,47	54,82

Fonte: elaborado pelos autores com base nos notebooks do projeto.

Os resultados demonstram diferenças relevantes entre os modelos baseline e o modelo estatístico aplicado. O modelo de Persistência apresentou melhor desempenho em MAE, indicando forte dependência de curto prazo na série analisada. Isso significa que o consumo do dia anterior possui grande influência na previsão do consumo do dia seguinte.

A Média Móvel de 7 dias apresentou o menor RMSE entre os modelos avaliados, o que sugere redução de erros elevados em alguns pontos da série. Entretanto, esse modelo pode suavizar excessivamente picos e quedas, perdendo sensibilidade diante de mudanças rápidas no consumo.

O modelo SARIMA incorporou explicitamente a sazonalidade semanal identificada na análise exploratória. Apesar de apresentar maior MAE e RMSE, obteve o menor MAPE percentual, indicando melhor aderência proporcional em algumas variações da série. Ainda assim, os resultados mostram que modelos estatísticos tradicionais podem não capturar integralmente padrões complexos ou não lineares existentes nos dados.

Entre as limitações do estudo, destacam-se o uso de apenas um consumidor da base, a agregação diária dos dados e a ausência de variáveis externas, como temperatura, feriados, tipo de atividade do consumidor e informações econômicas. Esses fatores podem influenciar o consumo e poderiam melhorar o desempenho dos modelos em trabalhos futuros.

5 CONCLUSÃO E PROJETOS FUTUROS

O presente trabalho permitiu aplicar conceitos de Ciência de Dados e séries temporais em um problema real de previsão de carga elétrica. A partir da base Electricity Load Diagrams 2011-2014, foi possível estruturar uma série temporal diária, realizar análise exploratória, criar atributos temporais e aplicar modelos preditivos iniciais.

A análise exploratória revelou padrões de tendência, sazonalidade semanal e dependência temporal no consumo do cliente MT_124. A transformação da série para frequência diária reduziu ruídos de alta frequência e tornou a modelagem mais adequada ao escopo acadêmico do projeto.

Os modelos baseline forneceram referências importantes para comparação. Observou-se que modelos simples, como a Persistência, podem apresentar desempenho competitivo em séries com forte dependência temporal de curto prazo. O SARIMA, por sua vez, demonstrou capacidade de incorporar sazonalidade, embora ainda apresente limitações para capturar padrões mais complexos.

Como projetos futuros, recomenda-se ampliar a análise para outros consumidores da base, testar modelos de aprendizado de máquina, como Random Forest, XGBoost e Gradient Boosting, e explorar modelos de deep learning, como LSTM. Também é recomendado incluir variáveis externas, como clima, feriados e informações econômicas, além de testar diferentes granularidades temporais e validação cruzada específica para séries temporais.

De modo geral, o projeto demonstra que técnicas de análise temporal podem contribuir para um planejamento energético mais eficiente e sustentável, auxiliando processos de tomada de decisão no setor elétrico.

REFERÊNCIAS

BOX, G. E. P.; JENKINS, G. M.; REINSEL, G. C.; LJUNG, G. M. Time Series Analysis: Forecasting and Control. 5. ed. Hoboken: Wiley, 2015.

CÁCERES, G.; TRONCOSO, A.; AGUILERA-MARTOS, I.; RÓDENAS, F.; RUEDA, M.; EXPÓSITO, A.; PÉREZ-CHAMARRO, E. ElectricityLoadDiagrams20112014. UCI Machine Learning Repository, 2014. Disponível em: <<https://archive.ics.uci.edu/dataset/321/electricityloadaddiagrams20112014>>. Acesso em: 28 fev. 2026.

EMPRESA DE PESQUISA ENERGÉTICA (EPE). Balanço Energético Nacional 2025: Relatório Síntese - ano-base 2024. Rio de Janeiro: EPE, 2025.

HOCHREITER, S.; SCHMIDHUBER, J. Long Short-Term Memory. Neural Computation, v. 9, n. 8, p. 1735-1780, 1997.

HONG, T.; FAN, S. Probabilistic electric load forecasting: a tutorial review. International Journal of Forecasting, v. 32, n. 3, p. 914-938, 2016.

HYNDMAN, R. J.; ATHANASOPOULOS, G. Forecasting: Principles and Practice. 3. ed. Melbourne: OTexts, 2021.